

Datos sísmicos

El artículo aborda la problemática de que la información detallada sobre la actividad sísmica en México generada por el Servicio Sismológico Nacional resulta sumamente técnica, visualmente poco amigable y compleja de manejar para la investigación, a pesar de que alrededor del 70% del país está expuesto a un alto riesgo sísmico debido a su ubicación en el Cinturón de Fuego del Pacífico y la interacción de cinco placas tectónicas. Esto es de vital importancia porque contar con herramientas accesibles permite fomentar la cultura de la prevención, respaldar la gestión gubernamental en la planeación territorial y facilitar el estudio científico. Para lograrlo, el sistema recopila información proveniente del Servicio Sismológico Nacional (más de 300,000 registros sísmicos desde 1900) y del INEGI (Censos de Población y Vivienda 2020 y Censos Económicos), los cuales se encontraban originalmente en archivos en formato CSV. Para poder utilizarlos, se desarrolló un programa en Python encargado de depurar campos vacíos, coordenadas inconsistentes y formatos incompatibles, generando un código SQL con los datos limpios que posteriormente se cargaron en PostgreSQL para estructurarlos como un almacén de datos (*data warehouse*).

En cuanto al modelado de la información, el sistema integra los hechos sísmicos (como magnitud, profundidad, fecha, hora y ubicación del epicentro) relacionándolos con dimensiones espaciales, demográficas y económicas que miden la población potencialmente afectada y la actividad productiva de las regiones. Gracias a esto, la herramienta es capaz de responder preguntas concretas como la distribución y frecuencia de sismos por estado y periodo —por ejemplo, analizando los sismos ocurridos en Jalisco en 2017—, la identificación de zonas densamente pobladas y centros económicos dentro del radio de alcance de un evento mediante mapas de calor, y la correlación entre la magnitud y la profundidad sísmica a lo largo de los 125 años de registros históricos. Finalmente, como limitaciones, los autores reconocen que la implementación y el despliegue técnico pueden dificultarse para usuarios sin experiencia previa en las herramientas utilizadas —a pesar de haber facilitado su ejecución mediante Docker Compose—, por lo que proponen como trabajo futuro la incorporación de visualizaciones en 3D, la integración de más fuentes de datos oficiales y la conexión con plataformas de alerta temprana.

Territorial Information Retrieval from Heterogeneous Open Data through the Construction of a Data Warehouse for Water Management in Mexico City

El artículo aborda la crisis hídrica en la Ciudad de México, caracterizada por la sobreexplotación de acuíferos, fugas en la red y el crecimiento poblacional. Aunque existen datos abiertos publicados por el gobierno (SACMEX) sobre el consumo de agua, estos se encuentran en formatos poco accesibles y carecen de herramientas de consulta. Esta situación es un problema importante porque la dispersión de la información limita su uso por parte de ciudadanos, investigadores y funcionarios para realizar diagnósticos urbanos y tomar decisiones basadas en evidencia.

Para resolver esto, los autores utilizaron la exportación de datos abiertos "Consumo Agua (1er Semestre 2019)" en formato CSV, complementada con series meteorológicas de Open-Meteo y cartografía de OpenStreetMap. Mediante el diseño de un proceso de Extracción, Transformación y Carga (ETL), extrajeron y limpiaron la información, descartando aquellos registros con coordenadas inconsistentes o valores faltantes en campos territoriales, logrando consolidar un almacén definitivo con 70,886 registros útiles.

La información se estructuró bajo un modelo dimensional de esquema de estrella alojado en PostgreSQL. En este modelo se identificaron tablas de hechos para medir el volumen de consumo de agua (fact_consumo_agua) y variables climáticas (fact_clima). Estas métricas se relacionaron con dimensiones conformadas de tiempo (fecha, año y bimestre), ubicación (alcaldía, colonia y coordenadas) y un índice de desarrollo socioeconómico. Además, el modelo fue mapeado de forma declarativa como un Grafo de Conocimiento validado con el estándar RDF Data Cube de la W3C, lo que permite modelar la geometría y adyacencia territorial como una red transitable.

El sistema resultante es capaz de responder preguntas concretas sobre cuál es el consumo total o promedio en territorios específicos y cómo varía a lo largo de los bimestres. Por ejemplo, el análisis reveló que las alcaldías Cuauhtémoc y Miguel Hidalgo lideran el consumo total en la ciudad. Gracias al grafo de conocimiento, el sistema también puede responder consultas topológicas complejas, como identificar qué colonias adyacentes (en un radio menor a 1.5 km) a una zona específica superan el consumo promedio. Asimismo, mediante un módulo exploratorio, responde cuáles colonias presentan consumos estadísticamente atípicos en comparación con sus vecinos, priorizando su inspección ante posibles fugas.

Finalmente, los autores reconocen limitaciones importantes, principalmente el alcance temporal de los datos, ya que están restringidos a tres bimestres de un solo año, lo que impide establecer correlaciones causales sólidas con épocas de sequía o lluvia. También señalan que el módulo de anomalías tuvo que ser evaluado con datos sintéticos por la falta de registros reales etiquetados sobre fugas, y que la adyacencia territorial se aproximó mediante puntos (centroides) en lugar de usar fronteras exactas. Como trabajo futuro, proponen integrar polígonos oficiales de las colonias para lograr relaciones topológicas exactas, materializar el grafo en un almacén persistente con un punto de consulta SPARQL público, alinear los identificadores con autoridades externas, y aplicar esta misma metodología de consolidación a otros dominios de datos urbanos, como la calidad del aire o el riesgo sísmico.

A Dimensional Data Warehouse for Geospatial Monitoring of Municipal Public Works, with an Evolution Path Toward a Lakehouse Architecture

El artículo aborda el desafío que enfrentan los gobiernos municipales ante el crecimiento acelerado de los datos de infraestructura pública, los cuales generan volúmenes heterogéneos que son difíciles de gestionar mediante hojas de cálculo o sistemas transaccionales aislados. Esta fragmentación representa un problema importante porque impide el análisis histórico, la detección temprana de retrasos y la participación ciudadana informada, lo cual afecta directamente la transparencia en la gestión de las obras públicas.

Los datos procesados por el sistema incluyen tanto información estructurada (texto, coordenadas, montos financieros) como archivos binarios no estructurados (fotografías y reportes en formato PDF). La recolección se realiza a través de una aplicación web y una API REST desarrollada en Flask/Python, la cual envía los datos estructurados a un esquema operativo en PostgreSQL y los archivos a un almacenamiento de objetos (Cloudflare R2). En lugar de utilizar trabajos ETL externos, el sistema emplea disparadores (triggers) en la base de datos para sincronizar y cargar la información hacia el almacén de datos dimensional. Para probar la plataforma, los autores no usaron registros reales, sino que generaron un conjunto de datos sintéticos que simuló la ejecución de 1,247 obras públicas distribuidas en 55 comunidades.

La información se modeló mediante un diseño de esquema de estrella compuesto por dos tablas de hechos y diez dimensiones. La tabla `fact_audit_events` registra eventos atómicos de auditoría y está particionada por año, mientras que la tabla `fact_work_monthly` almacena instantáneas mensuales que resumen el presupuesto y el avance físico de cada obra. Para garantizar la trazabilidad histórica, el modelo aplica Dimensiones Lentamente Cambiantes (SCD): cinco dimensiones son de Tipo 2 para mantener un historial de versiones (obras, regiones, empresas, personal y presupuesto), tres son de Tipo 1, y dos son catálogos fijos de Tipo 0. El modelo relacional también almacena los metadatos de las evidencias físicas, logrando un enlace bidireccional entre los hechos y el almacenamiento de objetos.

A través de seis vistas analíticas y un visor geoespacial interactivo, el sistema puede responder preguntas complejas que una hoja de cálculo no podría procesar. Por ejemplo, permite conocer la inversión por habitante en contraste con el índice de desarrollo de la comunidad, el nivel de concentración del presupuesto según la fuente de financiamiento y las tasas de participación ciudadana por región. Además, el módulo de detección alerta sobre problemas operativos respondiendo qué obras presentan retrasos extremos, cuáles tienen costos estadísticamente atípicos o qué proyectos muestran inconsistencias sospechosas entre un alto cobro financiero y un bajo avance físico real.

Los autores reconocen varias limitaciones en su trabajo, destacando que el sistema depende completamente de la calidad y frescura de los datos ingresados por los supervisores de campo, y que las evaluaciones analíticas se basaron exclusivamente en datos sintéticos debido a restricciones de privacidad. También admiten que el modelo de participación actual podría no representar a las minorías, y que su regla de detección de anomalías tiene un rendimiento modesto, siendo superada por un método no supervisado (Isolation Forest) y fallando especialmente al intentar identificar sobreprecios. Como trabajo futuro, proponen evolucionar la capa de almacenamiento hacia una arquitectura "lakehouse" completa adoptando formatos abiertos como Iceberg o Parquet. Asimismo, sugieren implementar un flujo de inferencia de visión por computadora para clasificar automáticamente el progreso de las obras a partir de las fotografías, aplicar modelos de series de tiempo para predecir las fechas de finalización, y publicar el esquema del sistema como un estándar de datos abiertos interoperable.